

Profil territorial des émissions de CO2 en France

Analyse descriptive des données

Tijou Louane & Gottschalk Eliott

2026-02-19

Table des matières

Introduction	2
1. Analyse univariée	3
Traitement des valeurs manquantes	3
Analyse univariée des variables quantitatives	4
Analyse univariée des variables qualitatives	7
2. Analyse bivariable	7
Variable quantitative - quantitative	7
Variable qualitative - qualitative	10
Variable qualitative - quantitative	10
3. Analyse factorielle	11
ACP sur l'ensemble des émissions de CO2 par département	12
ACP après regroupement des variables fortement corrélées	16
ACP sur les régions	19
ACP ratio des émissions de CO2 par habitant	20
ACP sur les ratios d'émissions	20
Conclusion	24
Annexe	25

Introduction

Au fil des années, les activités humaines ont entraîné une augmentation continue des émissions de CO₂, renforçant l'effet de serre et aggravant le réchauffement climatique. Il est donc essentiel de comprendre quels secteurs sont les plus émetteurs afin de mettre en place des politiques efficaces pour réduire ces émissions. Il est également important d'identifier les départements ou régions où la vigilance doit être renforcée, afin que les efforts de réduction soient équitablement répartis sur l'ensemble du territoire.

Cette étude porte sur les émissions de dioxyde de carbone (CO₂) des départements français par secteur d'activité. Les données proviennent du CITEPA¹, et ont été récupérées sur la plateforme officielle *data.gouv.fr* ([source](#))

La base recense exactement 12 variables donc 2 qualitatives indiquant le nom de la commune mais aussi son code Insee. Elle contient aussi 10 variables quantitatives sur lesquelles l'analyse en composante principale se réalise, ces variables correspondent aux émissions totales des émissions de CO₂ par secteurs pour chaque communes française(35 798) pour l'année 2016, comme l'agriculture, l'industrie, le secteur routier, tertiaire, résidentiel etc.

Notre objectif est de comprendre comment les émissions de CO₂ se répartissent entre les départements français selon les secteurs d'activité et s'il est possible d'identifier des profils départementaux d'émissions.

Pour ce faire, nous procéderons d'abord à une analyse univariée de chacune des variables, puis à une analyse bivariée afin d'étudier les relations entre elles. Ensuite, nous réaliserons une analyse factorielle, et plus particulièrement des analyses en composantes principales (ACP), avant de conclure sur les principaux résultats mis en évidence.


¹Centre Interprofessionnel Technique d'Études de la Pollution Atmosphérique

1. Analyse univariée

Avant toute analyse statistique, il est important de bien prendre connaissance du jeu de données afin de comprendre la distribution des variables et de détecter d'éventuelles anomalies, telles que les valeurs manquantes ou des valeurs abberantes. Nous procéderons donc à une première exploration des données grâce à une analyse univariée de chacune de nos variables.

Traitement des valeurs manquantes

Dans un premier temps, nous examinons la présence de valeurs manquantes au sein du jeu de données. Cette étape est essentielle car un taux élevé de données manquantes peut biaiser les analyses statistiques.



Nous observons que les variables *Autres_transports* et *Autres_transports_international* contiennent plus de 25 000 valeurs manquantes sur un total de 35 798 observations, ce qui représente environ 70 % des données. Étant donné cette proportion très élevée de données manquantes, nous avons pris la décision de supprimer ces deux colonnes pour éviter de fausser l'analyse.

Après avoir supprimé les variables avec trop de valeurs manquantes, comme le montre le graphique d'autres observations sont manquantes dans certains secteurs.

Cependant, ces valeurs manquantes, sont peu nombreuses par rapport à l'échantillon total et peuvent simplement être due à la réalité, c'est à dire que certaines communes peuvent très bien n'avoir aucune émissions de CO2 sur un secteur donné (par exemple si un département n'a pas de centre de déchet).

Comme nous agrégeons ensuite les communes par département (en faisant la moyenne des émissions par secteur), ces quelques valeurs manquantes n'ont pas d'impact significatif, la moyenne par département sera calculée sur les communes disponibles.

Agrégation par département

Pour simplifier l'analyse et faciliter la synthèse des données, nous créons une nouvelle variable *département*, correspondant aux deux premiers chiffres du code INSEE de chaque commune.

Cette nouvelle variable nous permet de regrouper les communes par département, et ainsi de travailler sur une analyse plus globale, plus facile à manipuler et à interpréter. Nous allons alors passer à une interprétation des profils moyens de communes au sein des départements, et non comme des niveaux totaux d'émissions départementales.

Concernant la vue des données manquantes, il ne reste plus qu'une valeur manquante pour le secteur de l'agriculture, correspondant au département de Paris. Après examen des données communales, toutes les valeurs pour les arrondissements (du 1er au 20e) sont manquantes pour ce secteur.

Cette absence de données reflète la réalité du territoire, Paris intra-muros est un département quasiment entièrement urbanisé, où l'activité agricole est inexistante dans les arrondissements et très peu présente dans la proche couronne². La valeur manquante a alors été imputée par 0.

L'analyse univariée est donc réalisée sur cette base agrégée de 96 départements, car c'est sur celle-ci que sera effectuée l'analyse en composantes principales.

Analyse univariée des variables quantitatives

Tableau 2 : Statistiques descriptives des variables quantitatives des émissions de CO2 pour les 96 départements français

Variable	Moyenne	Médiane	Q1	Q3	Minimum	Maximum	Ecart_type
Agriculture	2595.67	1964.64	1322.40	3497.53	0.00	7870.15	1942.17
Biomasse	3079.77	1503.92	1069.24	2573.95	402.86	59328.87	6910.40
Déchets	645.55	281.34	175.17	622.99	60.65	7347.16	1157.42
Energie	1033.40	184.88	107.64	355.24	34.97	39455.04	4227.94
Industrie	3260.79	1329.74	613.14	2413.93	99.33	86844.71	9353.33
Résidentiel	3803.31	1228.17	859.91	2483.35	326.74	96729.00	11277.33
Routier	5584.34	3085.45	2074.58	4723.56	966.12	81279.14	9740.37
Tertiaire	2460.49	797.30	508.02	1517.80	228.71	66581.50	7531.31


²Source : <https://driaaf.ile-de-france.agriculture.gouv.fr/les-espaces-agricoles-representent-2-5-du-territoire-de-paris-et-de-la-proche-a3478.html>

On remarque que quelques départements très émetteurs de CO₂ tirent fortement la moyenne vers le haut, tandis que la majorité des départements ont des niveaux d'émissions plus faibles. Par exemple, pour les déchets, la forte concentration géographique des infrastructures de traitement explique une médiane plutôt basse par rapport au maximum. De même, certains départements sont beaucoup plus industrialisés que d'autres.

Le même tableau est disponible en annexe sur les émissions de CO₂ par secteur mais au niveau communale³

Pour mieux comprendre la répartition des émissions de CO₂ par secteur dans les départements français, nous avons représenté des histogrammes afin de visualiser la distribution des émissions pour chacune des variables, c'est-à-dire pour chaque secteur.

Graphiques 2 : Histogrammes des variables quantitatives



La plupart des secteurs montrent une distribution étalée vers la droite, autrement dit la plupart des départements sont concentrés sur les mêmes niveaux d'émission de CO₂, sauf quelques départements qui se distinguent par des émissions très élevées. À cause des émissions très élevées de certains départements pour quelques secteurs, cela rend l'interprétation de la distribution de la majorité des données compliquée.

Pour mieux voir la répartition des émissions de la majorité des départements, nous avons ajusté l'échelle des histogrammes en nous focalisant sur les valeurs les plus fréquentes⁴. On observe ainsi que pour les secteurs industrie, résidentiel, routier, biomasse et tertiaire, les émissions de la grande majorité des départements se concentrent entre leur minimum et environ 10 000 tonnes équivalent CO₂. Le secteur de l'énergie présente une concentration plus basse, entre 34

³voir annexe: Tableau 1

⁴voir annexe: Graphiques 3

et 1 000 tonnes, tandis que celui des déchets se situe principalement entre 60 et 2 000 tonnes. Les concentrations d'émission restent présentes, indiquant que les départements ont tendance à émettre du CO₂ de manière casiment équivalente sauf pour certains.


Contrairement aux autres secteurs, les émissions du secteur agricole sont plus homogènes sur le territoire français et aucun département ne semble émettre ce type d'émission de manière extrême.

Ces conclusions peuvent se traduire par l'activité agricole globalement bien répartie sur l'ensemble du territoire, contrairement aux zones industrielles plus localisées.

L'analyse des densités complète les histogrammes⁵ en faisant apparaître des formes moins visibles. Elle met notamment en évidence, dans le secteur agricole, l'existence de deux groupes distincts de départements (une majorité à environ 2000 tonnes et un autre groupe à environ 6000 tonnes d'émissions de CO₂). Pour les autres secteurs, les pics marqués confirment que la majorité des départements présentent des émissions proches, tandis que les niveaux d'émission plus élevés concernent seulement quelques groupes de départements.

Ces distributions asymétriques nous amènent alors à regarder les boxplots afin d'identifier les valeurs potentiellement aberrantes ou atypiques.

Graphiques 5 : Boxplots des émissions de CO₂ par secteur



Les boîtes à moustache, situées vers le bas pour la majorité des secteurs nous amène à l'hypothèse que la grande majorité des départements français présentent des émissions relativement homogènes, et que l'essentiel de la pollution nationale est concentré sur l'ensemble du territoire.

⁵voir annexe: Graphiques 4

Les boxplots mettent également en évidence la présence de nombreuses valeurs extrêmes pour la plupart des secteurs. Ces valeurs ne traduisent pas des erreurs de mesure, mais reflètent des spécificités territoriales fortes (départements très industrialisés, fortement urbanisés ou spécialisés dans la production d'énergie). Elles ont donc été conservées, car elles constituent une information pertinente pour l'analyse des profils d'émissions.

En résumé, l'analyse descriptive met en évidence une forte homogénéité des émissions pour la majorité des départements, mais également une hétérogénéité marquée pour certains départements, avec des distributions très asymétriques et la présence de valeurs extrêmes. Cela amène à l'intuition de la réalisation d'une ACP afin d'identifier les profils départementaux

Analyse univariée des variables qualitatives


La base de données contient deux variables qualitatives (*dep_code* et *dep_nom*) correspondant à l'identification des départements. Ces variables servent uniquement de repères pour l'interprétation des résultats. Nous avons donc seulement vérifié l'absence de doublons afin de nous assurer que chaque département est bien représenté une seule fois. Ainsi, la réalisation de graphiques ou de tableaux de fréquence n'a pas été effectuée, car ils seraient illisibles vis à vis du nombre élevé de départements et n'apporteraient aucune information supplémentaire à l'analyse.

2. Analyse bivariée

Nous passons dès à présent à l'analyse bivariée afin d'étudier les relations entre nos variables. Cette analyse constitue une étape préalable essentielle avant la réalisation de l'ACP, puisqu'elle permet d'évaluer les dépendances et corrélation entre les variables.

Variable quantitative - quantitative

Graphique 7 : Corrélations des émissions de CO2 par secteur (Pearson)



Pour analyser les relations entre les variables quantitatives du jeu de données, soit les différents secteurs d'émissions de CO2, nous utilisons le coefficient de corrélation de Pearson, puisque cette matrice de corrélation servira par la suite à l'Analyse en Composantes Principales⁶.

Bien que toutes les variables soient exprimées en tonnes de CO2, les distributions sont asymétriques et présentent des valeurs extrêmes. Afin de vérifier les relations, nous avons également calculé le coefficient de corrélation de Spearman, fondé sur les rangs et moins sensible aux valeurs aberrantes⁷. Les résultats obtenus sont très similaires, ce qui confirme les relations observées entre les secteurs.

De manière générale, les variables quantitatives présentent de fortes corrélations positives. Les matrices de corrélation mettent en évidence des secteurs très corrélés (résidentiel, routier, biomasse et tertiaire) avec des coefficients supérieurs à 0,85 avec le coefficient de Pearson et de Spearman, indiquant une redondance informationnelle. Les départements fortement émetteurs de CO2 dans l'un de ces secteurs le sont également dans les autres. On remarque aussi une corrélation linéaire croissante quasi parfaite entre le secteur résidentiel et tertiaire une fois le coefficient de corrélation de Pearson arrondi (0,996). Cette relation est tout à fait normale car là où il y a de la densité humaine, on retrouve également une grande offre économique du secteur tertiaire.

⁶voir annexe: Graphiques 6

⁷voir annexe: Graphiques 8


Une autre corrélation très élevée est également observée entre les secteurs de l'énergie et de l'industrie (0,97), cela indique que plus le département émet des émissions de CO₂ en activité industrielle plus il a aussi tendance à en émettre avec la production énergétique.

À l'inverse, le secteur agricole présente des corrélations faibles et négatives avec les autres variables. Cela indique qu'un département plus spécialisé vers l'agriculture aura un profil d'émissions différent, avec de plus faibles émissions dans les autres secteurs par rapport à un département émettant peu de CO₂ lié à l'agriculture, tout en rappelant que ces relations restent faibles et sans impact important. Enfin on observe une corrélation quasiment nulle entre les émissions liées à l'agriculture et à l'énergie indiquant une absence de relation linéaire. Autrement dit, les variations des émissions agricoles n'expliquent pas celles du secteur énergétique.

Ces corrélations se vérifient également visuellement sur les nuages de points. On observe une forte relation linéaire positive entre les émissions du secteur résidentiel et celles du secteur routier. En revanche, le graphique comparant l'agriculture et le résidentiel montre une relation négative faible. On peut aussi constater l'influence de quelques valeurs extrêmes, qui s'écartent de la tendance générale. Sans ces valeurs, la relation serait probablement encore plus linéaire.

Ces interprétations amènent à penser au recours à une analyse en composantes principales afin de synthétiser l'information et d'identifier des profils territoriaux d'émissions. Il semblerait également qu'une acp contenant toutes les variables ne soit pas très pertinente en vue des fortes corrélations.

Graphique 9 : Relations entre les émissions de CO₂ de différents secteurs avec droites de régression



Variable qualitative - qualitative

Les variables *dep_code* et *dep_nom* contiennent la même information sous des formats différents. Par conséquent, la réalisation d'un tableau de contingence, d'un test du Khi² ou de graphiques croisés n'apporterait aucune information supplémentaire et serait alors illisible.


Nous avons vérifié, que les 96 lignes correspondent bien à des combinaisons différentes, à l'aide de la fonction *unique()*, ce qui confirme que chaque code départemental est associé à son nom. L'analyse bivariée pour ces variables n'est donc pas utile

Variable qualitative - quantitative

Dans cette partie, nous nous intéressons à la relation entre les émissions de CO2 par secteur (variable quantitative) et les départements (variable qualitative). L'objectif est d'examiner si certains départements ont des niveaux d'émissions différents selon les secteurs.

Une comparaison de moyenne par le test de student n'est pas appropriée pour notre jeu de donnée. Nous avons donc utilisé un graphique en barres empilées, pour observer les différences de profils d'émissions entre départements et secteurs.

Graphique 10 : Répartition des émissions de CO2 par secteur et département



Le graphique présente la répartition moyenne des émissions de CO2 par secteur pour chaque département en 2016. Les différences de hauteur des barres montrent que certains départements émettent beaucoup plus de CO2 que les autres. C'est notamment le cas pour Paris avec les secteurs routier et résidentiel. Les proportions des émissions par secteurs varient selon les

départements, mettant en évidence des profils d'émissions différents, comme la spécialisation dans l'industrie pour le département Bouches-du-Rhône.

Ce graphique permet d'identifier visuellement les départements et secteurs les plus émetteurs, mais afin de voir cela de manière plus détaillée, en annexe⁸ se trouve le détail de chaque secteur, permettant d'observer réellement quels sont les départements les plus émetteurs de CO₂ dans chaque secteur. En parallèle, le Top 10 des départements les plus émetteurs de CO₂ est observable en annexe⁹.

De manière générale, on observe que Paris, les Hauts-de-Seine, Seine-Saint-Denis, Bouches-du-Rhône et Val-de-Marne se situent dans la plupart des top 10 d'émission de chaque secteur, à l'exception du secteur de l'agriculture, qui regroupe plutôt les départements de Loire-Atlantique, Vendée ou même la Mayenne. Ainsi observer qu'un département figurant dans un des Top 10 a tendance à l'être dans les autres secteurs, à l'exception de l'agriculture, reflète les corrélations vues précédemment.

3. Analyse factorielle

Justification de l'Analyse en composantes principales

Nous passons maintenant à la partie d'analyse factorielle. Nous choisissons de réaliser une analyse en composantes principales (ACP), car notre jeu de données est composé principalement de variables quantitatives. L'ACP simplifie l'analyse en réduisant le nombre de variables sans perte significative d'information. Elle est particulièrement adaptée ici, car certaines variables sont corrélées, ce qui permet de synthétiser les relations entre secteurs. Elle permettra également de mieux comprendre les données et d'observer les regroupements de départements aux profils d'émissions de CO₂ similaires.

Indice KMO

Afin de vérifier que nos données sont pertinentes pour une analyse en composantes principales, nous avons calculé l'indice KMO¹⁰. Celui-ci permet d'évaluer si les corrélations entre variables sont suffisantes pour être synthétisées par une analyse factorielle.

Le résultat de l'indice KMO est supérieur à 0,6, il est exactement de 0,66, indiquant une adéquation moyenne, il y a des corrélations suffisantes entre certaines variables pour justifier une ACP ainsi l'analyse factorielle est pertinente.

⁸voir annexe: Graphiques 11

⁹voir annexe: Graphique 13

¹⁰voir annexe: Test 1

Test de Bartlett

Le test de normalité de Shapiro-Wilk¹¹ indiquent que toutes les variables sont significativement non normales ($p\text{-value} < 0,05$), ce qui signifie qu'elles ne suivent pas une loi normale.

Nous avons quand même réalisé le test de Bartlett¹² pour vérifier la présence de corrélations suffisantes entre les variables. Ce test est très significatif, et permet de rejeter l'hypothèse nulle d'indépendance entre les secteurs et confirme que des corrélations importantes existent. Cependant, étant donné l'asymétrie des données, ce test n'est pas fiable. La justification de l'ACP se fait donc essentiellement sur l'indice KMO.

Déterminant

Ensuite, nous vérifions le déterminant de la matrice de corrélation de Pearson¹³, qui est très faible ($6,67e-9$). Nous aurions pu utiliser les corrélations de Spearman au vu de l'asymétrie de la distribution de nos données, mais les conclusions sur les corrélations obtenues étant similaires, nous retenons la corrélation de Pearson, qui facilite l'interprétation et permet de conserver l'intensité des relations entre variables. Le déterminant très faible indique que certaines variables sont très fortement corrélées, mais pas parfaitement (comme observé dans l'analyse bivariée). Cette situation confirme que l'ACP est appropriée pour synthétiser l'information contenue dans les différents secteurs.

Nous réalisons dans un premier temps une ACP sur l'ensemble des variables initiales, car le déterminant n'est pas nul et ne nécessite donc pas la suppression immédiate de variables.

Puis, afin d'évaluer l'impact des corrélations quasiment parfaites et d'améliorer l'analyse, nous effectuons une ACP après regroupement des variables très fortement corrélées (corrélation $> 0,97$). Ainsi, les secteurs biomasse, résidentiel, tertiaire et routier sont regroupés en un premier bloc, et énergie et industrie dans un second.

ACP sur l'ensemble des émissions de CO2 par département

Cette ACP vise à mettre en évidence la structure sectorielle des émissions de CO2 des départements et à identifier d'éventuels profils d'émission communs.

Bien que toutes les variables soient exprimées dans la même unité (tonnes équivalent CO2), leurs dispersions et ordres de grandeur diffèrent fortement selon les secteurs. Le centrage-réduction est donc nécessaire afin d'éviter que les secteurs les plus émetteurs ne dominent l'analyse et afin de mettre en évidence les différences de profils d'émissions entre départements.

¹¹voir annexe: Test 2

¹²voir annexe: Test 3

¹³voir annexe: Test 4

Choix du nombre de dimensions


Pourcentage d'inertie expliquée et règle de Kaiser

Après analyse des valeurs propres de l'ACP¹⁴, on observe que les deux premières composantes principales expliquent 81,93% de la variance totale (Dim 1 : 61,9 %, Dim 2 : 19,9%). Ces deux axes contiennent donc l'essentiel de l'information et permettent de synthétiser efficacement les relations entre les secteurs et les départements. Nous avons donc choisi de retenir uniquement les deux premières composantes puisque les composantes suivantes n'expliquent qu'une part marginale de la variance.

Selon la règle de Kaiser, on ne conserve que les composantes dont la valeur propre est supérieure à 1. Ici, les deux premières composantes ont une valeur propre > 1 (Comp 1 : 4,96, Comp 2 : 1,59).

Éboulis des valeurs propres


Graphique 14 : Éboulis des valeurs propres de l'ACP



L'éboulis des valeurs propres montre une chute marquée après la deuxième composante, ce qui suggère que les deux premiers axes concentrent l'essentiel de l'information pertinente.

¹⁴voir annexe: Tableau 2

Graphique 15 : Contribution des variables à l'ACP



L'analyse des contributions montre que la première dimension, celle avec la majorité de l'information (62% de la variance expliquée) est principalement portée par les secteurs Biomasse, Résidentiel, Tertiaire et Routier de part leur couleur chaude mais aussi par leur qualité de représentation avec les flèches longues vers la droite. Cette observation de contribution à l'axe 1 est confirmée graphiquement¹⁵. Comme on l'observe les flèches de ces variables sont proches et orientées dans la même direction, illustrant leur forte corrélation, mais aussi leur corrélation à l'axe 1.

La deuxième dimension est dominée par les secteurs Énergie et Industrie avec une corrélation positive à cette axe. La dimension 2 représente donc l'axe secteur industriel, les variables sont aussi bien représentées sur le plan par la présence d'une longue flèche. Cette observation est confirmée graphiquement¹⁶. Les flèches correspondantes sont proches entre elles mais séparées du bloc résidentiel/tertiaire, ce qui souligne leur comportement spécifique. Le bloc Routier/Biomasse/Résidentiel/Tertiaire avec les flèches plutôt en bas indique qu'ils sont plutôt corrélés négativement à Dim2.


On suppose que les secteurs agriculture et déchets auraient principalement été expliqués par les dimensions secondaires que nous n'avons pas retenues pour l'analyse, indiquant un comportement plus spécifique. Graphiquement on voit que les variables sont peu représentées sur ce plan et par les axes, donc leurs corrélations avec Dim1 et Dim2 sont faibles. La variable déchets a

¹⁵voir annexe: Graphique 16

¹⁶voir annexe: Graphique 17

une flèche un peu plus longue mais pas autant que les autres indiquant une contribution plutôt modérée sur la dimension 1. Sur le plan, la flèche Agriculture pointe dans la direction opposée au bloc Routier/Biomasse/Résidentiel/Tertiaire, illustrant un comportement différent et une corrélation négative. Cependant, la faible longueur de la flèche du secteur Agriculture indique que cette opposition n'est pas très significative sur le plan, ce qui explique que la corrélation négative reste faible.


Graphique 18 : Projection des départements sur le plan



Sur le graphique des individus, on observe un nuage principal regroupant la majorité des départements, ce qui montre qu'ils ont des caractéristiques assez proches. Cependant, certains départements se détachent nettement : 13 (Bouches-du-Rhône), 76 (Seine-Maritime), 93 (Seine-Saint-Denis), 94 (Val-de-Marne) et 95 (Val-d'Oise). Ces points isolés sont éloignés des autres, indiquant qu'ils ont des profils particuliers et qu'ils contribuent fortement à la structure des axes principaux (leur cos2 élevé est visible par des couleurs chaudes). Le département 13 se distingue par sa forte contribution à Dim2, ce qui reflète sa forte activité industrielle et ses émissions de CO2 importantes pour le secteur énergétique. La présence des départements proche de l'Ile de France éloigné sur l'axe 1 indique leur spécialisation dans le bloc Routier/Biomasse/Résidentiel/Tertiaire qui confirme que cette dimension désigne l'urbanisation des départements mais aussi tiré par le secteur industriel et énergétique. Le département 76, quant à lui, se situe en dessous de l'axe 1, ce qui est probablement lié au port du Havre et aux larges mouvements routiers. Contrairement aux départements proche de Paris, il est moins influencé par le bloc industrie/énergie, ce qui reflète son profil portuaire spécifique.

Les axes permettent donc de distinguer les départements « typiques » du nuage principal et ceux ayant des comportements plus atypiques avec des profils d'émission différents, facilement repérables graphiquement grâce à leur éloignement.

Graphique 19 : Projection des départements et des variables sur le plan



Sur ce graphique combinant les départements et les secteurs d'émissions de CO₂, on peut voir plus directement les spécificités des secteurs d'émission par département. En effet, pour le département 13 (Bouches-du-Rhône), on aperçoit qu'il est spécialisé dans l'Énergie et l'Industrie. Pour le département 76 (Seine-Maritime), celui-ci est plus spécialisé dans le bloc des quatre secteurs très corrélés, soit les secteurs Biomasse, Résidentiel, Tertiaire et Routier. Nos intuitions précédentes sont donc confirmées ici.

ACP après regroupement des variables fortement corrélées

Comme précisé précédemment, nous avons également réalisé une Analyse en Composantes Principales (ACP) après avoir regroupé les variables très fortement corrélées en blocs (Bloc résidentiel : biomasse, résidentiel, tertiaire, routier/ Bloc Industriel : industrie et énergie). Après ce regroupement, le nombre de variables quantitatives est réduit à quatre, ce qui permet de limiter la redondance. Bien que ce nombre soit faible, l'analyse reste pertinente pour explorer les relations entre ces blocs mais son but n'est plus concrètement de réduire la dimension.

Nous avons recalculé l'indice KMO¹⁷, qui est supérieur à 0,6, indiquant que les corrélations entre variables sont suffisante pour réaliser l'ACP. De plus, le déterminant de la matrice de corrélation¹⁸ est bien différent de zéro (0,412), contrairement à la première ACP où il était


¹⁷voir annexe: Test 5

¹⁸voir annexe: Test 6

très proche de zéro, signe d'une forte multicollinéarité. Ces résultats confirment que l'ACP sur les blocs peut être réalisée.

La première composante principale explique 53 % de la variance¹⁹, et les deux premières composantes cumulées expliquent 76,7 % de la variance totale. Les composantes 3 et 4 apportent moins de 23 % supplémentaire, ce qui montre que l'essentiel de l'information est capturé par les deux premières composantes. Cette conclusion se confirme par l'ébouilissement des valeurs propres²⁰. Selon la règle de Kaiser, seule la première composante devrait être retenue, car sa valeur propre est supérieure à 1. Cependant, la deuxième composante possède une valeur propre proche de 1 (0,95) et, en la conservant, l'ACP permet de capturer une inertie totale supérieure à 53 %. Nous avons donc décidé de retenir les deux premières composantes pour l'analyse.

Graphique 21 : Contribution des variables à l'ACP




L'axe principal regroupe les trois blocs principaux et présente une corrélation positive avec les émissions totales : plus un département se situe à droite sur le graphique des individus, plus il est fortement émetteur plus le département possède un profil à la fois industriel et résidentiel. L'axe secondaire est fortement corrélé à l'agriculture : un département placé en hauteur sur cet axe possède donc une proportion importante d'émissions agricoles. La contribution de la variable agriculture à cet axe est particulièrement élevée, confirmant son rôle déterminant dans cette dimension. Cette nouvelle ACP permet ainsi de mettre en évidence les départements

¹⁹voir annexe: Tableau 3

²⁰voir annexe: Graphique 20

dont le profil d'émissions est orienté à la fois vers l'industrie et le secteur résidentiel (donc si le département est peuplé).

Graphique 22 : Projection des départements sur le plan




De manière logique, on retrouve les mêmes départements que précédemment, avec le 13 qui se situe en haut à droite, de par ses activités industrielles et énergétiques (port, raffinerie...). En plus, il s'agit d'un des départements possédant la plus grande densité de population en France. Selon la même logique, on observe des départements très peuplés avec une participation plus importante que la moyenne dans le secteur industriel.

Sur la partie gauche du graphe, on remarque que certains départements sortent de la masse grâce à la caractérisation de l'axe 2. On a par exemple des départements qui sortent du lot avec le Loiret (45), la Meurthe-et-Moselle (54), la Vienne (86) et l'Aveyron (12) qui sont des régions faiblement peuplées et principalement exploitées au service de l'agriculture et de l'élevage. L'axe 2 permet donc réellement ici d'indiquer quel département est concentré sur l'agriculture ou non.

Cependant, il faut prendre en compte les limites de cette représentation, à part les départements très émetteurs dans certains secteurs, on ne parvient pas à visualiser les différences entre départements car la plus part se retrouvent très proche sur le graphique. Dans un premier temps, on a essayé de supprimer de l'ACP les départements ayant un profil particulier mais sans succès car de nouveaux apparaissent alors, tirant les axes vers eux et empêchant à nouveau une interprétation claire et précise. On décide alors de se concentrer uniquement sur les départements proches les uns des autres.

Graphique 23 : Zoom sur la projection des départements sur le plan



Ce “zoom” réalisé sur la base du graphique précédent permet de mieux voir les relations entre départements et d’identifier lesquels sont à la fois industriels et fortement peuplés. Idem au niveau des départements avec un profil plus agricole, on remarque que la plupart sont des départements issus du grand ouest, notamment des pays de la Loire et de la Bretagne.

ACP sur les régions

Afin de vérifier nos résultats et éventuellement affiner nos conclusions, nous avons réalisé une nouvelle ACP, cette fois en regroupant les départements par région²¹. Sur le graphique des individus²², cela confirme que les départements du Grand Ouest sont fortement caractérisés par des émissions liées à l’agriculture, puisque l’on observe que les régions Pays de la Loire, Normandie et Bretagne sont tirées vers ce type d’émissions. La région Provence-Alpes-Côte d’Azur se distingue par des émissions principalement liées à l’énergie et à l’industrie principalement tirée par le département de Bouches-du-Rhône. Quant à l’Île-de-France, elle se caractérise par le secteur résidentiel. Encore une fois, la région se voit portée par la présence des départements vus précédemment (93,94,95). Pour le reste des régions, comme pour la majorité des départements, les profils sont plutôt homogènes et similaires, sans domination marquée d’un secteur particulier.

²¹voir annexe: Test 7 et 8, Tableau 4, Graphique 25

²²voir annexe: Graphique 26

Cette ACP ne révèle donc pas une structure différente de précédemment. Cependant elle a permis de synthétiser l'information sur les départements. On en tire ainsi les mêmes conclusions, indiquant que les deux ACP sont bien spécifiées au niveau de leurs dimensions.

ACP ratio des émissions de CO2 par habitant

On a également testé une ACP sur les émissions par habitants²³ en divisant les émissions de CO2 par le nombre d'habitants présents dans les départements, qui n'a rien donné de nouveau. On retrouve à peu près la même spécification des axes et donc les mêmes départements sont présents aux extrêmes tandis que tous les autres sont concentrés en un amas.

Au vu des différentes ACP réalisées jusqu'ici, on peut uniquement déterminer quels départements ont un profil à la fois résidentiel et industriel ou alors ceux portés par l'agriculture. Une solution pour obtenir plus de nuance est de créer une nouvelle colonne mesurant les émissions totales du département pour ensuite déterminer un ratio de chaque département pour chaque secteur. On peut ainsi reprendre la base initiale, sans les départements "extrêmes".

ACP sur les ratios d'émissions

Avec cette ACP, on ne cherche plus quel secteur est le plus émetteur. On va plutôt chercher à comprendre le profil de chaque département. C'est à dire, déterminer si le secteur a une tendance industrielle tout en étant peuplé ou bien si toutes ses émissions se concentrent uniquement sur le secteur résidentiel. On peut donc avoir des profils très diverses de mis en avant, permettant de mieux comprendre le dynamique et la structure des émissions de chaque territoire.

Justification de l'ACP

Le déterminant étant très faible²⁴, on décide de supprimer les variables apportant une redondance dans l'information. On décide de retirer tertiaire de cette ACP qui est fortement corrélé à résidentiel, selon les mêmes arguments que précédemment.

Le seul moyen d'avoir un KMO supérieur à 0.6 est en retirant la variable agriculture²⁵. En cause, la nature des émissions. On trouve rarement un département très urbanisé et très agricole donc il est probable que l'agriculture crée une dimension à elle seule. Ainsi, on obtient un déterminant de 0.35²⁶.

En étudiant les valeurs propres²⁷, on conserve uniquement les deux premières dimensions

²³voir annexe: ACP par habitant

²⁴voir annexe: Test 9

²⁵voir annexe: Test 10


²⁶voir annexe: Test 11

²⁷voir annexe: Tableau 5

comme le suggère la règle de Kaiser. Mais on notera que la troisième dimension est proche de 1 donc il semblerait qu'elle apporte une réelle précision dans la construction des axes

Le graphique des valeurs propres²⁸ vient confirmer les résultats précédents, seule 60% de l'information est comprise dans les deux premières dimensions. Cependant le reste des valeurs propres chute. On conservera donc deux dimensions pour cette acp.

Graphique 28 : Contribution des variables à l'ACP




La dimension 1 oppose d'un côté les départements où les émissions sont liées aux activités de production (industrielle et énergétique), on remarque par ailleurs que la superposition de leur flèche indique que ces variables sont très fortement corrélées positivement, et de l'autre, l'axe met en lumière les départements marqués par la mobilité, où le secteur Routier (incluant le transport de marchandises et de voyageurs) est le premier contributeur au profil d'émissions. Cet axe permet donc de distinguer les bassins de production des zones de transit ou de flux.

A l'inverse, l'axe 2 semble montrer la nature du mode de vie avec une caractérisation principalement sur les variables Résidentiel et Déchets. Cet axe permet donc d'indiquer si le département est grandement peuplé ou non. Ce secteur résidentiel semble sur le plan être perpendiculaire aux secteurs industrielle et énergétique indiquant une absence de corrélation. On comprend donc que le fait d'avoir calculé les ratios permet tout de suite d'apporter plus de nuance dans les différentes caractéristiques de chacun.

²⁸graphique 27

Malgré une faible contribution, on décide de conserver la variable Biomasse car c'est la seule à tendre vers le bas et donc apporter une information sur l'axe 2²⁹. Sa faible contribution dans les 2 premières dimensions est liée au fait qu'elle possède un comportement totalement différent des dynamiques observées ici. On remarque également que l'apport d'une troisième dimension serait plus que pertinente ici. Par ailleurs son opposition aux secteurs énergétique et industriel sur le plan indique une corrélation négative.

Graphique 31 : Projection des départements sur le plan



On observe ici 4 profils types, premièrement, le cadran haut-gauche montre les départements avec un profil plutôt industriel et urbain. On retrouve par exemple les bouches du rhone(13) et la Seine Maritime(76) qui sont deux des départements précédemment isolés, ce qui confirme leur profil très industriel, notamment porté par la présence de leurs ports respectifs. En haut à droite, on retrouve les départements où les émissions sont principalement liées au mode de vie urbain, avec un trafic routier conséquent. Logiquement, on y trouve des départements comme Paris et sa couronne qui sont très urbanisés. Leurs émissions sont presque exclusivement liées au mode de vie citadin (déchets, chauffage des bureaux/logements). En bas à gauche, on retrouve des départements ayant un profil industriel mais cette fois ci, largement moins peuplés avec donc une empreinte carbone liée en partie à la biomasse. On y retrouve par exemple le Morbihan avec une forte activité dans le domaine de l'agro alimentaire/construction navale ou encore la manche, où on retrouve à la fois la centrale de Flamanville mais aussi une production agro-alimentaire importante. En bas à droite, les départements ont une part prépondérante de la Biomasse dans le mix d'émissions, traduisant une part des émissions de déchets très faible.

²⁹tableau 6

Ces territoires restent cependant très dépendants du transit routier, car souvent moins peuplés et plus étendus (comme la corse) ou bien car ce sont des zones qui ont besoin d'acheminer des ressources.

Comme on a retiré l'agriculture de cette ACP, on a aussi une limite de représentativité avec la majorité des départements du grand ouest qui restent dans l'amas central. On pourrait donc émettre l'hypothèse que les territoires au centre du graphe sont caractérisés par un secteur agricole très important dans leurs émissions de CO₂. On observe malgré tout que certains s'orientent vers un des profils identifiés, par exemple le 44 qui est sur la partie haute-gauche, indiquant qu'il possède une activité industrielle. On comprend pourquoi tous les départements de cette région ne ressortaient pas sur la première ACP: certains ont une activité économique plus nuancée.

On remarque que quelques départements ne sont pas correctement expliqués par ce plan (points bleus/verts) ce qui montre bien l'importance de la Biomasse et l'utilité de réaliser une ACP en trois dimensions. Cette troisième dimension permettrait notamment de clarifier l'amas de département au centre du graphe, on pourrait alors avoir au minimum 4 profils bien distincts.

Conclusion

Au cours de cette étude, nous avons réalisé plusieurs ACP, d'abord sur les départements, en regroupant les variables corrélées entre elles, puis sur les régions et enfin en calculant les ratios des émissions par variables. Dans la première partie, nous avons vu que l'ACP permettait d'isoler très peu de départements/régions et n'isolait que ceux ayant des spécialisation à la fois industriels, urbanisés ou agricoles. On n'avait pas d'entre deux donc tout les autres départements se retrouvaient très proches sur le plan des différents graphes. Dans la seconde partie, les ratios ont permis de mettre en avant plusieurs profils de départements, parfois similaires aux premières ACP, mais on a surtout identifié quatres profils typiques et nuancés. L'apport de ces deux types d'ACP nous a été très utile car là où la deuxième identifiait quatres profils, elle ne prenait pas en compte l'agriculture et c'est là que l'ACP sur les données brutes permet d'identifier les profils plus agricoles. Nous avons donc réussi à correctement identifier les différents profils départementaux en combinant deux méthodes.

Grâce à notre étude, on comprend bien que certains départements concentrent la majeure partie des émissions dans un ou quelques secteurs. Mais on observe surtout que la majorité des départements possèdent des émissions dans les secteurs de manière assez homogène entre eux. C'est une manière de voir que la France en tant qu'état est globalement bien organisé et non divisé entre les régions. Chacun participe donc à sa manière à l'économie nationale, il serait donc ridicule de déclarer qu'un département est plus émetteur dans un des secteurs et d'uniquement cibler des politiques de réduction des émissions sur celui-ci. L'approche à adopter serait plutôt d'utiliser les profils trouvés dans ces ACP afin d'ensuite mener des études précises dans chacun de ces territoires pour construire une stratégie adaptée à chacun pour réduire les émissions de CO₂.


Notre étude possède malgré tout une limite majeure qui est que nous n'arrivons pas à obtenir une ACP avec des spécifications (KMO + déterminant) convenables simultanément pour avoir toutes les variables de prises en compte. Une autre limite est présente dans l'ACP sur les ratios, conserver uniquement deux dimensions cause un biais car la variable Biomasse construit à elle seule la troisième dimension. On a donc une perte d'information assez importante, qui doit être pris en compte dans les résultats finaux. Pour confirmer la pertinence des résultats obtenus voir obtenir d'autres catégories, on pourrait refaire l'étude en utilisant d'autres méthodes de clustering (k-means, hiérarchique, DBSCAN).

Annexe


Tableau 1 : Statistiques descriptives des variables quantitatives des émissions de CO2 par commune

	Variable	Moyenne	Médiane	Minimum	Maximum	Ecart_type
1	Agriculture	2459.9758	1559.381285	0.003431569	98949.32	2926.958
2	Biomasse	1774.3815	424.849988	3.758087577	576394.18	7871.342
3	Déchets	410.8063	54.748653	0.132243124	275500.37	4122.473
4	Energie	662.5698	4.709115	2.354557741	2535857.56	26455.714
5	Industrie	2423.1278	13.822427	1.052998302	6765118.85	56703.738
6	Résidentiel	1783.6779	227.091193	1.027266053	410675.90	8915.902
7	Routier	3535.5012	1070.895593	0.555092164	586054.67	9663.157
8	Tertiaire	1105.1659	216.297718	0.000000000	288175.40	5164.183


Graphiques 3 : Histogrammes zoomés des variables quantitatives




Graphiques 4 : Densités des variables quantitatives






Graphique 6 : Corrélation des émissions de CO2 par secteur (Pearson)






Graphique 8 : Corrélation des émissions de CO2 par secteur (Spearman)






Graphique 11 : Détails des émissions de CO2 par secteur et par département

\$Agriculture




\$Biomasse




\$Déchets

Émissions de CO2 – secteur Déchets par département




\$Energie


Émissions de CO2 – secteur Energie par département




\$Industrie




\$Résidentiel



\$Router



\$Tertiaire




Graphique 12 : Heatmap des émissions de CO2 par secteur et département

Heatmap des émissions par secteur et département



Graphique 13 : Top 10 des départements les plus émetteurs par secteurs



Résultat test 1 : Résultats de l'indice KMO pour l'ACP complète

Kaiser-Meyer-Olkin factor adequacy

Call: KMO(r = Base_dep[, variables_quantitatives])

Overall MSA = 0.66

MSA for each item =

Agriculture	Biomasse	Déchets	Energie	Industrie	Résidentiel
0.64	0.94	0.49	0.62	0.65	0.67
Routier	Tertiaire				
0.69	0.61				

Résultat test 2 : Test de normalité de Shapiro-Wilk pour les variables quantitatives

Agriculture	Biomasse
0.0000000352137555172906973	0.00000000000000000030540143
Déchets	Energie
0.0000000000000000002981066205	0.00000000000000000002391582
Industrie	Résidentiel
0.000000000000000000013493816	0.000000000000000000012115913
Routier	Tertiaire
0.0000000000000000000349008569	0.000000000000000000008974603

Résultat test 3 : Résultats du test de sphéricité de Bartlett pour l'ACP complète

\$chisq

[1] 1722.479

\$p.value

[1] 0

\$df

[1] 28


Résultat test 4 : Déterminant de la matrice de corrélation pour l'ACP complète

[1] 0.000000006674916


Tableau 2 : Valeurs propres et pourcentages de variance expliquée par chaque axe

	eigenvalue	percentage of variance	cumulative percentage of variance
comp 1	4.9595905476	61.994881845	61.99488
comp 2	1.5945430239	19.931787799	81.92667
comp 3	0.9465292795	11.831615994	93.75829
comp 4	0.4488483555	5.610604444	99.36889
comp 5	0.0242698678	0.303373347	99.67226
comp 6	0.0197557665	0.246947082	99.91921
comp 7	0.0057414787	0.071768483	99.99098
comp 8	0.0007216805	0.009021006	100.00000

Graphique 16 : Contribution des variables à la première composante principale



Graphique 17 : Contribution des variables à la deuxième composante principale



Résultat test 5 : Résultats de l'indice KMO pour l'ACP à 4 variables

```
Kaiser-Meyer-Olkin factor adequacy
Call: KMO(r = Base_dep_blocs_corrélé[, variables_quantitatives_blocs])
Overall MSA = 0.67
MSA for each item =
  Agriculture      Déchets Bloc_residentiel      Bloc_indus
        0.69         0.62         0.71         0.67
```


Résultat test 6 : Déterminant de la matrice de corrélation pour l'ACP à 4 variables

```
[1] 0.412024
```

Tableau 3 : Valeurs propres et pourcentages de variance expliquée par chaque axe

	eigenvalue	percentage of variance	cumulative percentage of variance
comp 1	2.1221467	53.053667	53.05367
comp 2	0.9477530	23.693824	76.74749
comp 3	0.5718869	14.297173	91.04467
comp 4	0.3582134	8.955335	100.00000

Graphique 20 : Eboulis des valeurs propres pour l'ACP après regroupement des variables fortement corrélées



Résultat test 7 : Résultats de l'indice KMO pour l'ACP par région

Kaiser-Meyer-Olkin factor adequacy

Call: KMO(r = Base_region_acp[, variables_quantitatives_blocs_reg])

Overall MSA = 0.51

MSA for each item =

Agriculture	Déchets	Energie	Industrie
0.27	0.56	0.58	0.51
Bloc_residentiel			
0.52			

Résultat test 8 : Déterminant de la matrice de corrélation pour l'ACP par région

[1] 0.0003704785


Tableau 4 : Valeurs propres et pourcentages de variance expliquée par chaque axe

eigenvalue	percentage of variance	cumulative percentage of variance
comp 1 3.249741424	64.9948285	64.99483


comp 2	0.926257264	18.5251453	83.51997
comp 3	0.794468364	15.8893673	99.40934
comp 4	0.022711869	0.4542374	99.86358
comp 5	0.006821079	0.1364216	100.00000

Graphique 24 : Eboulis des valeurs propres pour l'ACP par région


Warning in geom_bar(stat = "identity", fill = barfill, color = barcolor, :
Ignoring empty aesthetic: `width`.



Graphique 25 : Contribution des variables à l'ACP par région



Graphique 26 : Projection des régions sur le plan



ACP habitants : ACP ratio des émissions de CO2 par habitant

Warning: Setting row names on a tibble is deprecated.

Kaiser-Meyer-Olkin factor adequacy


Call: KMO(r = Base_dep_habs[, variables_quantitatives_blocs])


Overall MSA = 0.67

MSA for each item =

Agriculture	Déchets	Bloc_residentiel	Bloc_indus
0.69	0.62	0.71	0.67

[1] 0.412024





Résultat test 9 : Déterminant de la matrice de corrélation pour l'ACP par ratios

[1] 0.0000000000000000007072233

Résultat test 10 : Résultats de l'indice KMO pour l'ACP par ratios

[1] 0.0000000000000000007072233


Résultat test 11 : Déterminant de la matrice de corrélation pour l'ACP par ratios

[1] 0.3598809

Tableau 5 : Valeurs propres et pourcentages de variance expliquée par chaque axe

	eigenvalue	percentage of variance	cumulative percentage of variance
comp 1	2.0991345	34.985574	34.98557
comp 2	1.4310344	23.850574	58.83615
comp 3	0.9486465	15.810775	74.64692
comp 4	0.5909034	9.848391	84.49531
comp 5	0.5164690	8.607817	93.10313
comp 6	0.4138122	6.896869	100.00000

Graphique 29 : Contribution des variables à la première composante principale



Graphique 30 : Contribution des variables à la deuxième composante




Tableau 6: apport des variables pour chaque dimension

	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5
Routier	0.6174096	0.004235704	0.071696495896	0.154723343566	0.003465024
Biomasse	0.2174825	0.036722606	0.650401357221	0.000001395882	0.094518058
Energie	0.3554490	0.192500161	0.121306490159	0.300061431641	0.028461085
Industrie	0.4636778	0.252369036	0.000004429362	0.047529297174	0.102022545
Résidentiel	0.2520152	0.399190020	0.066696123829	0.086973740004	0.183276508
Déchets	0.1931004	0.546016904	0.038541615482	0.001614233983	0.104725785